

- 项目成果：满足项目要求交付工商银行，并上线工银智涌平台，开源 benchmark 加权分提升明显：Pangu-Finance-NLP-N2-128k 90.39、Deepseek R1 83.53、Qwen3 32B 84.69，详细对比可见华为云官网，<https://www.huaweicloud.com/product/pangu/industry.html>

华为技术有限公司，2012 实验室, 可信院, 应用安全技术实验室

2024.02-2025.05

• GUI Agent 安全 | 开发 Agent 注入攻击检测安全护栏

- 项目背景：终端小艺将推出可以操作手机的智能体，但是对 Agent 的安全隐患存在认知不足
- 端到端攻击验证：构建公司内部第一个针对 Agent 的注入攻击模式库，总结 10+ 有效攻击话术，在工程机完成端到端攻击验证
- 任务类 prompt 注入攻击检测安全护栏：设计快筛模块（Jaccard 匹配、特征建模、贝叶斯分类等）快速过滤白页面，满足时延要求；基于 BERT 设计注入攻击检测分类器，通过多阶段训练（对比学习、标签修正等）降低误报率，满足交付指标
- 项目成果：实现检出率大于 95%，误报率小于 0.05%，技术原型已交付终端小艺，保障 HDC 大会小艺智能体的安全发布

编程技能

Python(Tensorflow, Pytorch), Java, C/C++, R, SQL, Scala, Git

所获荣誉

院综合二等奖学金	2021.09
国家励志奖学金	2015.09, 2016.09
全国大学生数学竞赛专业组三等奖	2015.09
全国高中数学联赛省级一等奖	2013.09